



華南農業大學
South China Agricultural University

《深度学习》课程项目报告

题目： 电信客户流失预测与价值细分系统

小组成员： 202425310225-张嘉鹏 202425310201-陈国俊
202425310226-郑圣豪

专业班级： 24 计算机科学与技术 2 班

指导老师： 蓝 连 涛

开课时间： 2026-2027-1

评分：

评语：

摘要

电信行业客户流失问题日益严峻，新客户获取成本远高于存量客户维护成本。本项目构建了一套完整的“流失预警+客户分群”双模块分析系统，基于 Kaggle Telco Customer Churn 数据集（7,043 条记录，21 个特征），综合运用数据清洗、RFM 与 WOE 特征工程、SMOTE 过采样、四种分类模型对比（逻辑回归、随机森林、XGBoost、LightGBM）、SHAP 可解释性分析以及 K-Means/DBSCAN 聚类分析等方法。

实验结果表明，在真实不平衡测试集上，随机森林模型取得最佳综合性能（ROC-AUC = 0.8382, Recall = 0.7139, F1 = 0.6350）。K-Means 聚类成功将客户分为 4 个具有显著差异的群体，其中高危群体（Cluster 2）流失率高达 60.9%，高价值群体（Cluster 1）月均消费\$95 且流失率仅 21.3%。基于 SHAP 分析和聚类画像，提出了合同类型优化、增值服务捆绑、支付方式引导等六大方向的业务策略建议，为电信运营商的客户留存决策提供了数据驱动的支撑。

关键词：客户流失预测；机器学习；SMOTE；SHAP 可解释性；客户细分；集成学习

1. 引言

1.1 问题定义

在电信行业，客户流失（Customer Churn）指客户主动停止使用运营商服务的行为。随着市场竞争日趋激烈，运营商之间的客户争夺成本不断攀升。研究表明，获取一个新客户的成本是维护一个老客户的 5 至 6 倍，而客户留存率每提升 5%，企业利润可增加 25%至 95%[1]。因此，准确预测客户的流失倾向、深入理解流失驱动因素、制定针对性的客户留存策略，对于电信企业保持竞争力和盈利能力具有重要的商业价值。

1.2 研究意义

传统的客户流失管理往往采取被动的事后补救措施，效果有限且成本高昂。数据挖掘与机器学习技术的快速发展为主动式流失管理提供了技术基础。通过构建预

测模型，企业可以在客户做出离网决策之前识别高风险客户群体，从而提前采取精准的干预措施。此外，借助 SHAP (SHapley Additive exPlanations) 等可解释性工具，模型分析结果可以由“黑箱预测”转变为可理解、可操作的业务洞察[2]。

1.3 项目目标

本项目的目标是构建一个完整的“流失预警 + 客户分群”双模块分析系统。具体包括三个层次：

- 有监督学习模块：对比逻辑回归、随机森林、XGBoost 和 LightGBM 四种分类算法，通过 SMOTE 处理类别不平衡，以 ROC-AUC 和 Recall 为核心指标，选出最佳流失预测模型。
- 无监督学习模块：利用 K-Means 和 DBSCAN 对客户进行聚类细分，识别不同价值群体及其流失风险特征。
- 可解释性与业务应用：通过 SHAP 分析揭示特征对流失预测的贡献方向与大小，结合聚类画像，输出可落地的业务策略建议。

2. 相关工作

客户流失预测是数据挖掘领域的经典问题，国内外学者已开展了广泛的研究工作。本节从传统统计方法、集成学习、不平衡学习策略、深度学习方法以及模型可解释性五个方面进行综述。

2.1 传统统计方法

早期研究主要采用逻辑回归 (Logistic Regression) 和决策树 (Decision Tree) 等传统方法。Lemmens 和 Croux[3]使用逻辑回归对美国电信公司客户数据建模，发现合同类型和在网时长是最具预测力的变量。该类方法的优势在于模型可解释性强，训练和推理速度快，但面对高维特征和非线性关系时预测能力有限。Burez 和 Van den Poel[6]的研究进一步指出，单一的传统分类器在处理类别不平衡时性能下降明显。

2.2 集成学习方法

随着算法发展，集成学习方法在流失预测中展现出优越性能。XGBoost (eXtreme Gradient Boosting) 由 Chen 和 Guestrin[4] 于 2016 年提出，通过梯度提升框架实现高效的特征选择和 L1/L2 正则化，已成为工业界的主流方案。LightGBM 由 Ke 等人[5] 于 2017 年提出，基于直方图算法和叶子优先 (leaf-wise) 的生长策略，进一步优化了训练速度与内存占用，在大规模数据集上表现突出。Breiman[13] 提出的随机森林则通过 Bagging 策略和多棵决策树的投票机制，天然具有良好的抗过拟合能力。

2.3 不平衡学习策略

客户流失数据通常存在严重的类别不平衡问题（流失客户占比往往不到 30%）。Chawla 等人[7] 于 2002 年提出的 SMOTE (Synthetic Minority Oversampling Technique) 通过在特征空间中合成少数类样本，有效缓解了不平衡问题，成为该领域引用最高的方法之一。Verbeke 等人[8] 从利润驱动的角度出发，提出代价敏感学习 (Cost-Sensitive Learning) 框架，通过为少数类赋予更高的误分类代价来优化模型的实际商业价值。

2.4 深度学习与图神经网络方法

近年来，深度学习也被引入客户流失预测领域。Wangperawong 等人[9] 使用时间卷积网络 (TCN) 建模客户行为时序特征，取得了优于传统方法的预测精度。然而，Grinsztajn 等人[10] 在 2022 年的系统性研究中指出，对于中小规模的结构化表格数据，精心调参的集成树模型（如 XGBoost、LightGBM）往往不逊色于甚至优于深度神经网络。

2.5 模型可解释性

随着机器学习模型在业务场景中的广泛应用，模型可解释性变得愈发重要。Ribeiro 等人[11] 于 2016 年提出了 LIME (Local Interpretable Model-agnostic Explanations)，通过局部线性近似来解释单个预测。Lundberg 和 Lee[2] 于 2017 年提出的 SHAP 基于博弈论中的 Shapley 值，为每个特征分配对预测结果的贡献值，

兼具局部解释和全局解释的能力。在企业实际应用中，SHAP 已成为解释树模型预测的主流工具。

本项目在上述研究基础上，综合运用 SMOTE 过采样、四种分类模型对比、SHAP 解释和聚类分析，构建一个完整、可解释、可落地的客户流失预测与价值细分系统。

3. 数据集

3.1 数据来源与规模

本实验使用 Kaggle 平台公开的 Telco Customer Churn Dataset[12]。该数据集模拟了某电信运营商 7,043 名客户的订阅信息，包含 21 个特征变量（含 1 个目标变量），被广泛应用于客户流失预测的教学与研究。

数据集的特征可分为三大类别，如表 1 所示。

类别	特征名称	说明
人口统计	gender, SeniorCitizen, Partner, Dependents	性别、是否老年人、是否有伴侣、是否有家属
账户信息	tenure, Contract, PaperlessBilling, PaymentMethod, MonthlyCharges, TotalCharges	在网时长、合同类型、无纸化账单、支付方式、月费、总费
服务订阅	PhoneService, MultipleLines, InternetService, OnlineSecurity, OnlineBackup, DeviceProtection, TechSupport, StreamingTV, StreamingMovies	电话服务、多线路、互联网服务类型、在线安全等 9 项增值服务

目标变量	Churn	是否流失 (Yes/No)
------	-------	---------------

3.2 数据分布分析

目标变量 Churn 的分布存在明显的类别不平衡：在 7,043 名客户中，5,174 名未流失（73.46%），1,869 名已流失（26.54%），流失与非流失比例约为 1:2.8。图 1 展示了目标变量的分布情况（见附录 experiments/target_distribution.png）。

3.3 数据预处理流程

数据预处理包含以下五个步骤：

- 缺失值处理：经检查，数据集无显式 NaN 缺失值，但 TotalCharges 列存在 11 个空字符串记录（对应 tenure = 0 的新客户），将其转为 NaN 后用中位数填充。
- 无关特征移除：移除 customerID 列，该列为客户唯一标识符，对预测任务无贡献。
- 目标变量编码：将 Churn 列中的“Yes”/“No”映射为 1/0，便于模型处理。
- 类别特征编码：对 15 个类别型特征（gender、Partner、Contract 等）采用 Label Encoding 进行数值化编码。
- 异常值检测：采用 IQR（四分位距）方法对 tenure、MonthlyCharges、TotalCharges 三个核心数值特征进行检测。检测结果显示数据质量较好，无超出 1.5 倍 IQR 范围的异常值。

3.4 数据增强策略

针对类别不平衡问题（流失:非流失 $\approx$ 1:2.8），采用 SMOTE 进行数据增强。SMOTE 通过在特征空间中为每个少数类（流失客户）样本选择 k 个近邻，在样本与其近邻之间随机线性插值生成合成样本。SMOTE 处理后，训练集样本数由 5,634 增至 8,278，两类样本达到 1:1 平衡。值得注意的是，SMOTE 仅在训练集上执行，测试集保持原始分布以真实评估模型泛化能力。

4. 方法

4.1 系统总体架构

本项目的技术架构分为四个阶段：数据层（数据加载、清洗、EDA 探索性分析）、特征层（RFM 特征构建、WOE 分箱编码、特征重要性预筛选）、模型层（SMOTE 过采样、四种分类模型训练与对比、K-Means/DBSCAN 客户聚类）、应用层（SHAP 可解释性分析、聚类画像、业务策略输出）。

4.2 特征工程

特征工程是本项目的核心环节，包括 RFM 特征构建和 WOE 分箱编码两部分。

（1）RFM 特征构建

借鉴零售领域的 RFM（Recency-Frequency-Monetary）模型，为电信场景定制三个复合特征。R 指标（Recency）定义为 $R = 1/(\text{tenure} + 1)$ ，数值越高表示客户越“新”，处于流失高风险期。F 指标（Frequency）统计客户订阅的增值服务数量（共 9 项），反映使用频率和客户粘性。M 指标（Monetary）直接用 MonthlyCharges 衡量客户消费价值。此外，构建 RFM 综合评分以捕捉三维特征的联合效应。

（2）WOE 分箱编码

Weight of Evidence（证据权重）是一种有监督的离散化编码方法，尤其适用于逻辑回归等线性模型。WOE 的计算方式为：对每个分箱，计算好客户（未流失）与坏客户（流失）在该分箱中占比之比的对数值，即 $WOE = \ln[(\text{好客户占比}) / (\text{坏客户占比})]$ 。WOE 值反映了每个分箱中两类客户的比例差异，绝对值越大表示该分箱对预测目标的区分能力越强。本实验对 tenure、MonthlyCharges、TotalCharges 三个核心数值特征采用等频分箱（ $q = 10$ ），生成对应的 WOE 编码特征。

4.3 分类模型

本实验对比四种分类算法，参数设置如表 2 所示。

模型	类型	关键参数	特点
逻辑回归	线性分类器	C=1.0, solver=liblinear, max_iter=1000	可解释性强，训练快速，作为线性基线
随机森林	Bagging 集成	n_estimators=200, max_depth=10, min_samples_split=10	抗过拟合，特征重要性评估，无需特征缩放
XGBoost	Boosting 集成	n_estimators=200, max_depth=6, lr=0.1, subsample=0.8	L1/L2 正则化，梯度提升框架，工业界首选
LightGBM	Boosting 集成	n_estimators=200, max_depth=6, lr=0.1, num_leaves=31	直方图算法，leaf-wise 生长，速度快，内存省

4.4 损失函数与优化器

逻辑回归使用交叉熵损失（Cross-Entropy Loss），优化器为 liblinear（坐标下降法）。XGBoost 和 LightGBM 使用二分类对数损失（Binary Logloss），优化器为各自的梯度提升框架。随机森林基于基尼不纯度（Gini Impurity）进行节点分裂，不需要梯度优化。

4.5 评估策略

评估指标包括 Accuracy（准确率）、Precision（精确率）、Recall（召回率）、F1-Score、ROC-AUC 和 PR-AUC 六项。其中 ROC-AUC 是模型区分能力的综合指标，Recall 直接反映流失客户的识别率，PR-AUC 在不平衡场景下比 ROC-AUC 更具

参考价值。验证方法采用 5 折分层交叉验证 (StratifiedKFold, shuffle = True)，数据按 80%训练/20%测试分层划分 (stratify = y)，SMOTE 仅在训练集上执行。随机种子固定为 42，确保实验完全可复现。

4.6 客户聚类

K-Means 聚类基于 RFM 特征 (tenure, MonthlyCharges, TotalCharges, R_Score, F_Score, M_Score, RFM_Total)，先通过标准化消除量纲差异，再使用肘部法则 (Elbow Method) 和轮廓系数 (Silhouette Score) 联合确定最佳 K 值 (K = 4)。为对比验证，同时采用 DBSCAN (eps = 0.5, min_samples = 10) 进行基于密度的聚类，识别异常客户群体 (噪声点)。

4.7 模型可解释性

使用 SHAP (SHapley Additive exPlanations) 进行模型解释。SHAP 值基于博弈论中 Shapley 值的理论框架，将每个预测结果分解为各特征的贡献之和。对于树模型，采用 TreeExplainer 实现高效的 SHAP 值计算；分析时采样 500 个训练样本以平衡计算效率与统计代表性。

5. 实验

5.1 实验设计

本实验包含三个层次的对比：（1）模型层面——逻辑回归 vs 随机森林 vs XGBoost vs LightGBM；（2）特征层面——原始特征（19 维）vs 原始特征 + RFM + WOE 编码（27 维）的消融对比；（3）聚类层面——K-Means（固定簇数）vs DBSCAN（密度自适应）。

5.2 5 折交叉验证结果

在 SMOTE 处理后的平衡训练集（8,278 样本）上进行 5 折分层交叉验证，结果如表 3 所示。

模型	Accuracy	Precision	Recall	F1	ROC-AUC
Logistic Regression	0.8195 ± 0.0076	0.7977 ± 0.0076	0.8562 ± 0.0136	0.8259 ± 0.0079	0.9089 ± 0.0039
Random Forest	0.8384 ± 0.0099	0.8193 ± 0.0093	0.8683 ± 0.0150	0.8430 ± 0.0101	0.9175 ± 0.0035
XGBoost	0.8530 ± 0.0089	0.8531 ± 0.0077	0.8529 ± 0.0140	0.8529 ± 0.0094	0.9337 ± 0.0040
LightGBM	0.8524 ± 0.0071	0.8499 ± 0.0068	0.8560 ± 0.0097	0.8529 ± 0.0073	0.9325 ± 0.0041

在平衡后的训练集上，四种模型均表现良好，XGBoost 以 ROC-AUC = 0.9337 位居第一，体现了梯度提升集成学习的优势。四种模型的标准差均较小（< 0.015），表明模型性能稳定可靠。

5.3 测试集评估结果

在保持原始分布（流失率 26.54%）的真实测试集上评估，结果如表 4 所示。这是最能反映模型实际应用价值的评估场景。

模型	Accuracy	Precision	Recall	F1	ROC-AUC	PR-AUC
Logistic Regression	0.7594	0.5362	0.6925	0.6044	0.8359	0.6587
Random Forest	0.7821	0.5717	0.7139	0.6350	0.8382	0.6527
XGBoost	0.7779	0.5788	0.5989	0.5887	0.8220	0.6313
LightGBM	0.776	0.577	0.588	0.582	0.822	0.635

GBM	4	4	2	8	0	3
-----	---	---	---	---	---	---

在真实不平衡数据上，随机森林以 $\text{ROC-AUC} = 0.8382$ 和 $\text{Recall} = 0.7139$ 取得综合最佳表现。这意味着模型能够成功识别 71.4% 的流失客户，同时保持 57.2% 的精确率。逻辑回归虽然整体准确率最低，但其 Recall（流失客户召回率）达到 0.6925，与集成方法相当，说明线性模型在 RFM 和 WOE 特征工程的加持下仍具有竞争力。XGBoost 和 LightGBM 在平衡训练集上表现突出（ $\text{ROC-AUC} > 0.93$ ），但在真实不平衡测试集上存在一定程度的过拟合。

5.4 ROC 与 PR 曲线分析

四种模型的 ROC 曲线均显著优于随机猜测基线（ $\text{AUC} = 0.50$ ）。（完整 ROC 和 PR 曲线图见附录 `experiments/roc_curves.png` 和 `pr_curves.png`）。在不平衡分类问题中，PR 曲线比 ROC 曲线更具参考价值。由于流失客户仅占 26.5%，随机猜测的 PR-AUC 基线约为 0.27。四种模型的 PR-AUC 在 0.63 至 0.66 之间，远超基线，说明模型具有良好的实用价值。

5.5 混淆矩阵分析

从混淆矩阵可以看出（见附录 `experiments/confusion_matrices.png`），四种模型对非流失客户的识别准确率较高（真负例多），但对流失客户存在一定程度的漏检（假负例）。以随机森林为例，374 个真实流失客户中有 267 个被正确识别（ $\text{Recall} = 71.4\%$ ），107 个被漏检。这是不平衡分类的典型特征——模型倾向于预测多数类。在实际业务中，可通过调整分类阈值来平衡精确率与召回率。

5.6 特征重要性分析

随机森林模型的特征重要性排序显示（见附录 `experiments/feature_importance.png`），Contract（合同类型）是最重要的预测特征（重要性 = 0.139），其次是 R_Score（重要性 = 0.094）、tenure（重要性

= 0.082) 和 MonthlyCharges (重要性 = 0.075)。RFM 综合评分 RFM_Total 和 WOE 编码特征也进入了 Top-10。

5.7 消融实验

为验证 RFM + WOE 特征工程的有效性，使用仅含原始特征（无 RFM/WOE，19 维）的数据集进行消融对比，结果如表 5 所示。

实验条件	Logistic Regression AUC	Random Forest AUC
原始特征（19 维）	0.8035	0.8221
原始特征 + RFM + WOE（ 27 维）	0.8359 (+0.032)	0.8382 (+0.016)

特征工程为逻辑回归带来了+0.032 的显著 AUC 提升，为随机森林带来+0.016 的提升。这说明 RFM 和 WOE 特征能够为线性模型提供额外的非线性区分能力，验证了领域知识驱动特征构建的有效性。

6. 结果分析

6.1 SHAP 可解释性分析

为理解模型的决策机制，对最佳模型（随机森林）进行 SHAP 分析。SHAP 特征重要性排名如表 6 所示（完整 SHAP 可视化见附录 experiments/shap_summary.png）。

排名	特征	SHAP Importance	业务含义
1	tenure_WOE	0.0592	在网时长的证据权重编码，反映客户生命周期的非线性影响
2	RFM_Total	0.0592	RFM 综合评分，

			同时考虑了最近性、频率和消费价值
3	MonthlyCharges	0.0557	月消费金额，高消费客户流失倾向略有增加
4	PaymentMethod	0.0557	支付方式，电子支票支付者流失风险显著偏高
5	InternetService	0.0271	互联网服务类型，光纤用户流失率高于 DSL 用户
6	MultipleLines	0.0271	多线路服务，与互联网服务类型高度相关
7	R_Score	0.0246	最近性指标，新客户流失风险高于老客户
8	TotalCharges	0.0246	累计消费总额，长期客户的总消费更高但流失率更低

SHAP 分析与随机森林特征重要性相互印证，共同指出：tenure（在网时长）、RFM 综合评分、MonthlyCharges（月费用）、PaymentMethod（支付方式）和 InternetService（互联网服务类型）是驱动客户流失的核心因素。值得注意的是，Contract（合同类型）虽然在相关性分析中排名第一，但在 SHAP 模型归因中因与其他特征（如 tenure、PaymentMethod）存在共线性而权重有所稀释。

6.2 客户聚类画像

K-Means (K = 4) 将客户分为四个特征差异显著的群体，画像特征如表 7 所示（完整可视化见附录 experiments/kmeans_clustering.png 和 cluster_radar.png）。

聚类	人数	流失率	月均消费	在网时长	特征画像	策略方向
Cluster 0	2,517 (35.7%)	30.4%	\$64	中等	中等消费、中等忠诚度	交叉销售增值服务
Cluster 1	2,226 (31.6%)	21.3%	\$95	较长	高消费、高忠诚度、VIP 群体	核心 VIP 维护
Cluster 2	946 (13.4%)	60.9%	\$58	较短	月付为主、短在网、极高流失风险	高危优先干预
Cluster 3	1,354 (19.2%)	4.1%	\$21	长	低消费、高稳定性、基础服务用户	稳定群体保持

聚类结果清晰揭示了客户价值的异质性：Cluster 1 是高价值 VIP 群体（月均 \$95，流失率 21.3%），是运营商利润的核心来源；Cluster 2 是急需干预的高危群体（流失率 60.9%，946 人），若不加干预将造成大量客户流失；Cluster 3 是稳定但低价值的群体（流失率仅 4.1%）。

6.3 DBSCAN 聚类对比

DBSCAN (eps = 0.5, min_samples = 10) 的聚类结果与 K-Means 形成互补（见附录 experiments/dbscan_clustering.png）。DBSCAN 自动识别了若干个密集客

户群体，同时标记出部分“噪声点”——这些客户的行为模式明显异于主流群体，可能对应着异常账户、欺诈行为或特殊需求客户，值得进一步的人工调查。与 K-Means 的对比表明，两种聚类方法各有优势：K-Means 适合业务分组和策略制定，DBSCAN 适合异常检测和个案分析。

6.4 错误案例分析

对随机森林模型的错误预测进行抽样分析，发现两类典型的错误模式。假阴性（FN，预测“不流失”实际“流失”）：此类客户往往具有中等在网时长和中等月消费，其行为特征与“忠诚客户”相似但实际已流失。这提示我们需要更多的行为动态特征（如最近三个月的费用变化趋势、服务使用频率变化）来捕捉流失前兆信号。假阳性（FP，预测“流失”实际“不流失”）：此类客户多为月付合同、使用电子支票支付的在网客户。虽然模型将其判定为“高风险”，但这些客户可能因为习惯或惯性而暂时未流失，实际上是“潜在流失客户”，提前干预仍具有预防价值。

7. 业务策略建议

基于模型分析结果和聚类画像，提出六大方向的业务策略建议，汇总如表 8 所示。

策略	数据发现	具体措施	预期效果
合同类型优化	月付客户流失率远超长期合同客户	推出有吸引力的 1 年/2 年合同套餐，提供折扣或免费增值服务作为签约激励	降低流失率 15-20%
增值服务捆绑	未订阅 OnlineSecurity/TechSupport 者流失率显著偏高	对高危客户免费试用 1 个月安全服务，体验后引导付费转化	提升客户粘性和服务切换成本
支付方式引导	电子支票支付者流失率是自动转账者的 2-3 倍	引导客户转为自动转账/信用卡支付，给予小额账单折	提升客户生命周期价值

		扣作为激励	
分群精准运营	不同聚类群体流失风险和 价值差异显著	Cluster 1: VIP 权益升级和专属客服 ; Cluster 2: 针对性优惠券和主动外呼 ; Cluster 0: 交叉销售增值服务; Cluster 3: 保持现有服务	精准投放, 提升运营 ROI
早期预警系统	tenure (在网时长) 是最重要的预测特征	建立分级预警: 3 个月内加强新手引导, 6-12 月推送个性化优惠, 12 月以上启动忠诚度计划	早期干预, 降低新客户流失
光纤服务优化	Fiber Optic 用户付费高但流失率也较高	排查光纤服务体验痛点 (网速稳定性、客服响应), 针对性改善	降低高 ARPU 客户流失率 10%

上述建议均基于数据分析和模型输出的客观结论，实施前建议进行小规模 A/B 测试以验证策略有效性。

8. 结论与展望

8.1 主要发现

(1) 在模型性能方面，随机森林在真实不平衡测试集上以 $ROC-AUC = 0.8382$ 、 $Recall = 0.7139$ 的综合表现成为最优模型。SMOTE 过采样有效提升了所有模型对流失客户的识别能力，将 Recall 从基线水平提升了约 15 至 20 个百分点。

（2）在关键特征方面，SHAP 分析和随机森林特征重要性一致表明，tenure（在网时长）、RFM 综合评分、MonthlyCharges（月费用）、PaymentMethod（支付方式）和 InternetService（互联网服务类型）是驱动客户流失的核心因素。

（3）在客户分群方面，K-Means 将客户分为 4 个具有明显差异的群体。其中 Cluster 2（946 人，流失率 60.9%）是需要优先干预的高危群体；Cluster 1（2,226 人，月费\$95，流失率 21.3%）是高价值 VIP 客户，需要重点维护。

（4）在特征工程价值方面，RFM + WOE 特征工程为线性模型带来了 0.032 的显著 AUC 提升，验证了领域知识驱动特征构建的有效性。

8.2 局限性

（1）数据规模有限：数据集仅包含 7,043 条记录，对于捕捉所有流失模式可能不够充分。（2）特征维度受限：缺少客户行为时序数据（如通话记录变化、投诉历史），这些动态信息对流失预测可能更为关键。（3）外部因素缺失：未考虑竞争对手活动、经济环境变化等外部因素对客户流失的影响。（4）模型泛化性：实验基于单一数据集，尚未在其他电信企业数据上验证模型的迁移能力。

8.3 未来改进方向

（1）引入 MLP、Wide&Deep 等神经网络模型进行对比实验，探索深度学习在结构化数据上的潜力。（2）构建客户行为的时间序列特征（如费用的环比/同比变化率、服务使用的增减趋势），捕捉流失的动态前兆。（3）探索 Tomek Links、ENN 等欠采样方法与 SMOTE 的组合策略，寻找更优的不平衡处理方案。（4）设计在线 A/B 测试框架，评估策略的实际业务效果。（5）开发实时流失预测与自动告警系统，实现模型工程化落地。（6）引入外部数据源（区域经济指标、社交媒体情感分析等）丰富特征维度。

参考文献

[1] Reichheld F F, Sasser W E. Zero defections: quality comes to services[J]. Harvard Business Review, 1990, 68(5): 105-111.

- [2] Lundberg S M, Lee S I. A unified approach to interpreting model predictions[C]. Advances in Neural Information Processing Systems, 2017: 4765–4774.
- [3] Lemmens A, Croux C. Bagging and boosting classification trees to predict churn[J]. Journal of Marketing Research, 2006, 43(2): 276–286.
- [4] Chen T, Guestrin C. XGBoost: a scalable tree boosting system[C]. Proceedings of the 22nd ACM SIGKDD, 2016: 785–794.
- [5] Ke G, Meng Q, Finley T, et al. LightGBM: a highly efficient gradient boosting decision tree[C]. Advances in NIPS, 2017: 3146–3154.
- [6] Burez J, Van den Poel D. Handling class imbalance in customer churn prediction[J]. Expert Systems with Applications, 2009, 36(3): 4626–4636.
- [7] Chawla N V, Bowyer K W, Hall L O, et al. SMOTE: synthetic minority over-sampling technique[J]. Journal of Artificial Intelligence Research, 2002, 16: 321–357.
- [8] Verbeke W, Dejaeger K, Martens D, et al. New insights into churn prediction in the telecommunication sector[J]. European Journal of Operational Research, 2012, 218(1): 211–229.
- [9] Wangperawong A, Brun C, Laudy O, et al. Churn analysis using deep convolutional neural networks and autoencoders[J]. arXiv:1604.05377, 2016.
- [10] Grinsztajn L, Oyallon E, Varoquaux G. Why do tree-based models still outperform deep learning on typical tabular data?[C]. Advances in NIPS, 2022.
- [11] Ribeiro M T, Singh S, Guestrin C. “Why should I trust you?”: explaining the predictions of any classifier[C]. Proceedings of the 22nd ACM SIGKDD, 2016: 1135–1144.
- [12] IBM. Telco Customer Churn Dataset[DB/OL]. Kaggle, <https://www.kaggle.com/datasets/blastchar/telco-customer-churn>, 2018.
- [13] Breiman L. Random forests[J]. Machine Learning, 2001, 45(1): 5–32.
- [14] Pedregosa F, Varoquaux G, Gramfort A, et al. Scikit-learn: machine learning in Python[J]. Journal of Machine Learning Research, 2011, 12: 2825–2830.

[15] McInnes L, Healy J, Melville J. UMAP: uniform manifold approximation and projection for dimension reduction[J]. arXiv:1802.03426, 2018.

附录

附录 A: 实验环境

项目	版本/说明
操作系统	Windows 11
Python	3.12
NumPy	1.26.4
Pandas	2.2.2
Scikit-learn	1.4.2
XGBoost	3.3.0
LightGBM	4.6.0
SHAP	0.46.0
imbalanced-learn	0.12.3

附录 B: 可复现性说明

所有实验均固定随机种子（`random_state = 42`），数据按 80%/20% 分层划分（`stratify = y`），交叉验证使用 5 折 `StratifiedKFold`（`shuffle = True`）。SMOTE 仅在训练集上执行，测试集保持原始分布。完整的 Notebook 和 Python 脚本见代码附件。运行命令为：`pip install -r requirements.txt && jupyter notebook Telco_Customer_Churn_Analysis.ipynb`。

附录 C: 可视化图表索引

- `target_distribution.png` — 目标变量分布图（count + 饼图）
- `numeric_distributions.png` — 数值特征分布直方图与箱线图

- categorical_churn_rate.png — 类别特征流失率对比图（16 个子图）
- correlation_matrix.png — 特征相关性热力图
- feature_importance_preliminary.png — 随机森林特征重要性预分析
- feature_importance.png — 最佳模型特征重要性排序
- smote_comparison.png — SMOTE 过采样前后对比
- model_comparison.png — 四种模型性能对比柱状图
- roc_curves.png — ROC 曲线对比
- pr_curves.png — Precision-Recall 曲线对比
- confusion_matrices.png — 四种模型混淆矩阵
- shap_summary.png — SHAP 可解释性分析图
- elbow_method.png — 肘部法则确定最佳 K 值
- kmeans_clustering.png — K-Means 客户聚类散点图 + 饼图
- cluster_radar.png — 聚类画像雷达图
- dbscan_clustering.png — DBSCAN 密度聚类对比图